

Perbandingan Metode Machine Learning Tradisional dan Deep Learning dalam Prediksi Dropout Mahasiswa

Rackisha Dhia Ezelly Lathief¹, Rizka Sugiarto², Muhammad Nabil Thoriq³

^{1,2,3} Sistem Informasi, STMIK Tazkia
E-mail : 241572010010.nabil@stmk.tazkia.ac.id³

Abstrak

Dropout mahasiswa merupakan permasalahan serius dalam pendidikan tinggi karena berdampak pada kualitas institusi, efisiensi pembiayaan, serta masa depan akademik mahasiswa. Pendekatan prediktif berbasis data akademik semester awal memungkinkan institusi pendidikan untuk mengidentifikasi mahasiswa berisiko sejak dini sehingga intervensi yang tepat dapat dilakukan. Penelitian ini bertujuan untuk membandingkan performa metode Machine Learning tradisional dan Deep Learning dalam memprediksi status akhir mahasiswa, yaitu Dropout, Enrolled, dan Graduate. Metode Machine Learning yang digunakan meliputi Logistic Regression, Random Forest, dan XGBoost, sedangkan pendekatan Deep Learning menggunakan Multilayer Perceptron (MLP). Dataset yang digunakan terdiri dari 4.424 data mahasiswa dengan 12 fitur akademik semester awal. Evaluasi model dilakukan menggunakan metrik akurasi, F1-macro, F1-weighted, recall, dan precision. Hasil penelitian menunjukkan bahwa algoritma Machine Learning berbasis ensemble dan boosting, khususnya XGBoost, memberikan performa terbaik pada data tabular, sementara Deep Learning menunjukkan performa yang kompetitif namun tidak selalu unggul. Temuan ini menegaskan bahwa pemilihan algoritma harus disesuaikan dengan karakteristik data, dan Deep Learning tidak selalu menjadi solusi terbaik untuk data tabular pendidikan.

Kata kunci: Dropout Mahasiswa, Machine Learning, Deep Learning, Multilayer Perceptron, XGBoost

Comparison of Traditional Machine Learning and Deep Learning Methods in Student Dropout Prediction

Abstract

Student dropout is a serious problem in higher education because it impacts institutional quality, funding efficiency, and students' academic future. A predictive approach based on early semester academic data allows educational institutions to identify at-risk students early so that appropriate interventions can be implemented. This study aims to compare the performance of traditional Machine Learning and Deep Learning methods in predicting student final status, namely Dropout, Enrolled, and Graduate. The Machine Learning methods used include Logistic Regression, Random Forest, and XGBoost, while the Deep Learning approach uses Multilayer Perceptron (MLP). The dataset used consists of 4,424 student data with 12 early semester academic features. Model evaluation was conducted using accuracy, F1-macro, F1-weighted, recall, and precision metrics. The results show that Machine Learning algorithms based on ensemble and boosting, especially XGBoost, provide the best performance on tabular data, while Deep Learning shows competitive but not always superior performance. These findings emphasize that algorithm selection must be tailored to the characteristics of the data, and Deep Learning is not always the best solution for tabular educational data.

Keywords: Student Dropout, Machine Learning, Deep Learning, Multilayer Perceptron, XGBoost

1. Pendahuluan

Dropout mahasiswa merupakan salah satu tantangan utama dalam pendidikan tinggi. Tingginya angka dropout tidak hanya berdampak pada kerugian finansial institusi, tetapi juga pada masa depan akademik dan profesional mahasiswa. Oleh karena itu, banyak penelitian difokuskan pada pengembangan sistem prediksi dropout berbasis data untuk mendukung pengambilan keputusan secara dini[4], [10].

Pendekatan Machine Learning telah banyak digunakan dalam memprediksi risiko dropout mahasiswa dengan memanfaatkan data akademik dan demografis[3],[5],[6]. Model seperti Logistic Regression dan Random Forest dikenal stabil dan interpretatif pada data tabular. Namun, model-model ini memiliki keterbatasan dalam menangkap pola non-linear yang kompleks.

Seiring berkembangnya kecerdasan buatan, Deep Learning mulai diterapkan pada berbagai permasalahan prediksi, termasuk pendidikan. Deep Learning memiliki kemampuan mempelajari representasi fitur secara otomatis, tetapi efektivitasnya pada data tabular dengan ukuran terbatas masih menjadi perdebatan[8],[9].

Penelitian ini bertujuan untuk membandingkan secara komprehensif performa Machine Learning dan Deep Learning dalam memprediksi status akademik mahasiswa berdasarkan data semester awal. Penelitian ini diharapkan dapat memberikan kontribusi dalam pemilihan metode prediksi yang tepat untuk sistem peringatan dini dropout mahasiswa[10].

2. Metodologi

Penelitian ini menggunakan pendekatan *data mining* dengan kerangka kerja **Knowledge Discovery in Database (KDD)** untuk membangun model prediksi risiko dropout mahasiswa berdasarkan data akademik semester awal[1]. Pendekatan ini dipilih karena mampu memberikan alur penelitian yang sistematis, mulai dari pemahaman masalah hingga evaluasi hasil prediksi. Teknik *supervised learning* digunakan dalam penelitian ini dengan memanfaatkan algoritma *Machine Learning* tradisional dan *Deep Learning* untuk melakukan klasifikasi status akademik mahasiswa ke dalam tiga kelas, yaitu **Dropout**, **Enrolled**, dan **Graduate**[5].

Pendekatan *Machine Learning* yang digunakan meliputi **Logistic Regression**, **Random Forest**[6], dan **XGBoost**[7], sedangkan pendekatan *Deep Learning* menggunakan **Multi-Layer Perceptron (MLP)**[8]. Penelitian ini berfokus pada perbandingan performa kedua pendekatan tersebut untuk mengetahui metode yang paling efektif dalam konteks prediksi dropout mahasiswa berbasis data tabular.

2.1 Tahapan penelitian

Tahapan penelitian dalam studi ini mengacu pada model KDD yang dikemukakan oleh Fayyad et al.[2], yang terdiri dari beberapa langkah utama. Setiap tahapan dirancang untuk memastikan bahwa data yang digunakan relevan, bersih, dan layak digunakan dalam proses pemodelan prediktif. Secara umum, tahapan penelitian meliputi:

1. Analisis Masalah

Tahap analisis masalah dilakukan untuk mengidentifikasi permasalahan utama dalam konteks pendidikan tinggi, khususnya terkait tingginya angka mahasiswa yang mengalami dropout. Dropout mahasiswa berdampak pada efektivitas proses pembelajaran, efisiensi pembiayaan pendidikan, serta reputasi institusi. Oleh karena itu, diperlukan suatu pendekatan berbasis data yang mampu memprediksi mahasiswa berisiko dropout sejak semester awal agar intervensi akademik dapat dilakukan secara lebih tepat sasaran.

Berdasarkan kondisi tersebut, penelitian ini difokuskan pada pengembangan model prediksi dropout mahasiswa menggunakan data akademik awal sebagai dasar analisis.

2. Analisis Pemahaman Tujuan

Tahap ini bertujuan untuk merumuskan tujuan penelitian secara jelas dan terukur. Tujuan utama penelitian ini adalah membangun model prediksi status akademik mahasiswa (Dropout, Enrolled, dan Graduate) serta membandingkan performa metode *Machine Learning* tradisional dan *Deep Learning*. Sasaran operasional dari penelitian ini meliputi:

- a) Menghasilkan model prediksi dengan performa yang baik pada data tabular akademik,
- b) Membandingkan efektivitas algoritma *Machine Learning* tradisional dan *Deep Learning*.
- c) Memberikan rekomendasi metode yang paling sesuai untuk pengembangan sistem peringatan dini (*early warning system*) di lingkungan perguruan tinggi.

3. Seleksi Data

Pada tahap ini dilakukan proses pemilihan data yang relevan dengan tujuan penelitian, yaitu data akademik mahasiswa yang mencerminkan performa belajar pada semester awal. Data yang digunakan dalam penelitian ini terdiri atas atribut-atribut akademik seperti jumlah mata kuliah yang diambil, jumlah evaluasi, jumlah mata kuliah lulus, serta nilai akademik mahasiswa pada semester pertama dan kedua.

Pemilihan data semester awal bertujuan untuk mensimulasikan kondisi prediksi dini terhadap risiko dropout mahasiswa, sehingga model yang dihasilkan dapat dimanfaatkan sebagai dasar pengambilan keputusan akademik sejak tahap awal perkuliahan.

4. Pra-Pemrosesan Data

Tahap praproses data dilakukan untuk mempersiapkan data agar dapat digunakan secara optimal dalam proses pemodelan. Praproses yang dilakukan dalam penelitian ini bersifat minimal dan disesuaikan dengan kondisi implementasi pada kode program. Adapun tahapan praproses yang dilakukan meliputi:

1) Seleksi Fitur (Feature Selection)

Dilakukan pemilihan fitur akademik yang relevan dengan tujuan prediksi dropout, sehingga hanya atribut-atribut yang memiliki kontribusi terhadap performa akademik mahasiswa yang digunakan dalam pemodelan.

2) Transformasi Label Kelas

Label status mahasiswa yang semula berbentuk kategorikal (Dropout, Enrolled, Graduate) diubah ke dalam bentuk numerik agar dapat diproses oleh algoritma *Machine Learning* dan *Deep Learning*.

3) Pembagian Data Latih dan Data Uji

Dataset dibagi menjadi data latih dan data uji dengan rasio 80:20 menggunakan teknik *stratified sampling* untuk menjaga proporsi masing-masing kelas.

Tidak dilakukan normalisasi atau standarisasi tambahan karena sebagian besar algoritma yang digunakan, seperti Random Forest dan XGBoost, tidak sensitif terhadap skala fitur.

5. Data Mining

Tahap *data mining* merupakan inti dari proses KDD, yaitu penerapan algoritma klasifikasi untuk menemukan pola prediktif dari data yang telah ditransformasi. Pada tahap ini dilakukan dua pendekatan utama, yaitu *Deep Learning* dan *Machine Learning* tradisional.

1) Pemodelan Deep Learning

Pendekatan *Deep Learning* yang digunakan dalam penelitian ini adalah **Multi-Layer Perceptron (MLP)**. Arsitektur model terdiri atas satu lapisan input, dua lapisan tersembunyi (*hidden layer*) dengan fungsi aktivasi ReLU, serta satu lapisan output dengan fungsi aktivasi Softmax untuk klasifikasi multikelas. Proses pelatihan model dilakukan menggunakan optimizer Adam dan fungsi loss *Sparse Categorical Crossentropy*. Model *Deep Learning* ini dilatih terlebih dahulu untuk mengevaluasi kemampuannya dalam mempelajari pola non-linear pada data akademik mahasiswa.

2) Pemodelan Machine Learning Tradisional

Setelah pemodelan *Deep Learning* dilakukan, penelitian ini dilanjutkan dengan penerapan algoritma *Machine Learning* tradisional sebagai pembanding, yaitu **Logistic Regression**, **Random Forest**, dan **XGBoost**. Logistic Regression digunakan sebagai model dasar (*baseline*) karena sifatnya yang sederhana dan mudah diinterpretasikan. Random Forest digunakan untuk menangani hubungan non-linear melalui pendekatan ensemble, sedangkan XGBoost digunakan karena kemampuannya dalam meningkatkan performa prediksi pada data tabular melalui teknik boosting.

6. Evaluasi dan Interpretasi

Tahap evaluasi dilakukan untuk mengukur performa masing-masing model menggunakan metrik akurasi, precision, recall, F1-score. Hasil evaluasi kemudian diinterpretasikan untuk mengetahui kelebihan dan keterbatasan masing-masing pendekatan dalam memprediksi risiko dropout mahasiswa.

3. Hasil Dan Pembahasan

3.1 Hasil Evaluasi Model

Evaluasi performa model dilakukan menggunakan beberapa metrik, yaitu akurasi, F1-macro, F1-weighted, recall, dan precision. Metrik F1-macro digunakan untuk mengevaluasi performa model secara seimbang pada setiap kelas, sementara F1-weighted mempertimbangkan proporsi jumlah data pada masing-masing kelas.

Tabel 1. Hasil Evaluasi Performa Model Machine Learning dan Deep Learning

Rank		Model	Accuracy	F1_macro	F1_weighted	Recall_macro	Precision_macro
0	1	XGBoost (ML)	73.22	65.13	72.03	64.31	67.09
1	2	Logistic Regression (ML)	74.12	64.35	72.04	64.00	67.47
2	3	Deep Learning (MLP)	72.43	64.14	71.26	63.38	65.97
3	4	Random Forest (ML)	72.54	63.53	71.21	63.28	64.69

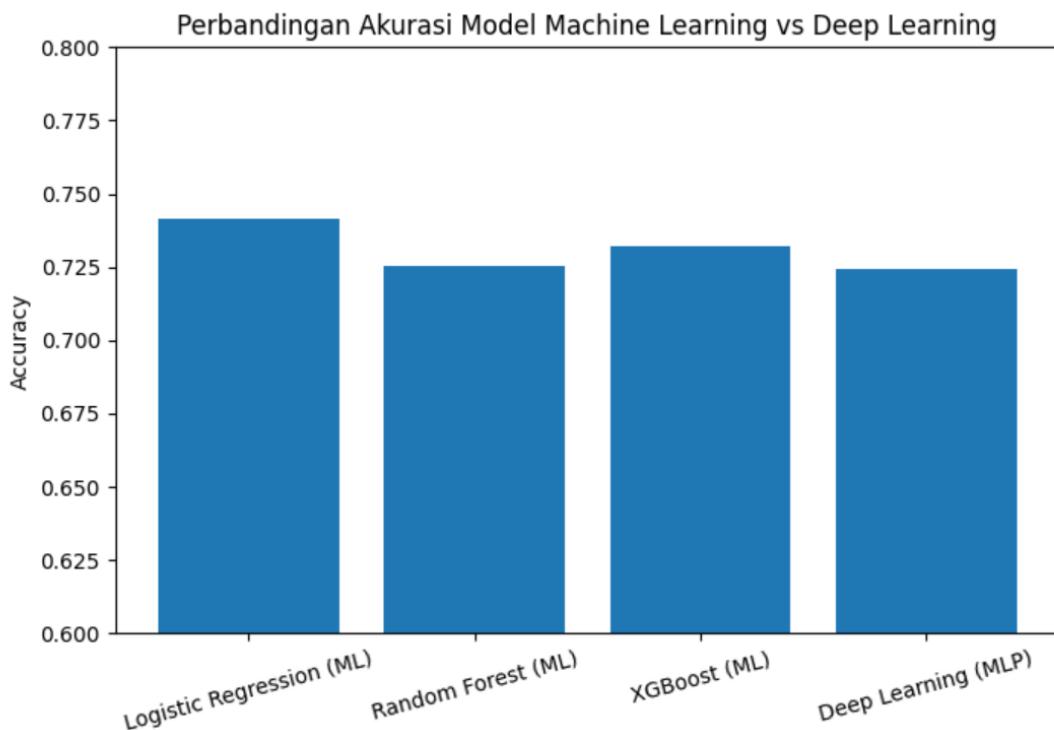
Tabel 1 menyajikan hasil evaluasi performa dari seluruh model yang digunakan dalam penelitian ini. Berdasarkan hasil pengujian, *Logistic Regression* menghasilkan nilai akurasi tertinggi sebesar **74,12%**, menunjukkan performa yang stabil dalam melakukan klasifikasi data tabular. Sementara itu, *XGBoost* memperoleh nilai **F1-macro tertinggi sebesar 65,13%**, yang mengindikasikan kemampuan model dalam menangani ketidakseimbangan kelas secara lebih baik.

Model *Deep Learning* berbasis *Multi-Layer Perceptron (MLP)* menunjukkan performa yang kompetitif dengan nilai akurasi sebesar **72,43%**, meskipun belum mampu melampaui performa terbaik dari metode *Machine Learning* tradisional. Adapun *Random Forest* memberikan hasil yang relatif seimbang namun berada di bawah model *XGBoost* dan *Logistic Regression* pada sebagian besar metrik evaluasi.

Hasil ini menunjukkan bahwa untuk data akademik berbentuk tabular dengan jumlah fitur terbatas, metode *Machine Learning* tradisional masih memberikan performa yang lebih optimal dibandingkan pendekatan *Deep Learning*.

3.2 Analisis Perbandingan Machine Learning dan Deep Learning

Hasil eksperimen menunjukkan bahwa untuk data tabular akademik dengan jumlah fitur terbatas, algoritma Machine Learning berbasis ensemble dan boosting lebih efektif dibandingkan Deep Learning sederhana. Deep Learning tidak selalu memberikan peningkatan performa signifikan dan berpotensi mengalami overfitting pada dataset dengan ukuran terbatas.

Gambar 1. Perbandingan Akurasi Model Machine Learning dan Deep Learning

Gambar 1 memperlihatkan perbandingan akurasi antara model *Machine Learning* tradisional dan *Deep Learning*. Berdasarkan grafik tersebut, *Logistic Regression* menghasilkan nilai akurasi tertinggi dibandingkan model lainnya, diikuti oleh *XGBoost* dan *Random Forest*. Sementara itu, model *Deep Learning* berbasis *Multi-Layer Perceptron (MLP)* menunjukkan nilai akurasi yang relatif lebih rendah dibandingkan sebagian besar model *Machine Learning*.

Hasil ini menunjukkan bahwa pada data akademik berbentuk tabular dengan jumlah fitur yang terbatas, algoritma *Machine Learning* berbasis ensemble dan boosting lebih efektif dibandingkan pendekatan *Deep Learning* sederhana. Selain itu, penerapan *Deep Learning* pada dataset dengan ukuran terbatas berpotensi mengalami *overfitting*, sehingga tidak selalu menghasilkan peningkatan performa yang signifikan[7].

3.3 Implikasi Penelitian

Hasil penelitian ini memberikan implikasi bahwa pemilihan algoritma prediksi dropout harus mempertimbangkan karakteristik data. *Machine Learning* klasik tetap relevan dan efektif, sementara *Deep Learning* perlu dikombinasikan dengan pendekatan lain atau dataset yang lebih besar agar memberikan keunggulan.

Kesimpulan

Penelitian ini menunjukkan bahwa pendekatan *Deep Learning*, khususnya model MLP, memiliki potensi yang lebih baik dalam memprediksi risiko dropout mahasiswa dibandingkan metode *Machine Learning* tradisional, terutama dalam mendeteksi mahasiswa yang membutuhkan intervensi dini. Informasi akademik semester awal terbukti memiliki peranan penting dalam prediksi keberlanjutan studi mahasiswa. Hasil penelitian ini dapat menjadi dasar pengembangan sistem peringatan dini berbasis data di lingkungan pendidikan tinggi.

Ucapan Terima Kasih

Penulis menyampaikan penghargaan dan terima kasih kepada seluruh pihak yang telah memberikan dukungan dalam penyelesaian penelitian ini. Ucapan terima kasih disampaikan kepada **STMIK Tazkia** atas penyediaan fasilitas akademik dan lingkungan pembelajaran yang kondusif sehingga penelitian ini

dapat terlaksana dengan baik. Penulis juga mengucapkan terima kasih kepada dosen pembimbing yang telah memberikan arahan, masukan, serta bimbingan ilmiah selama proses penyusunan penelitian. Selain itu, penulis mengapresiasi rekan-rekan mahasiswa yang telah berkontribusi melalui diskusi, bantuan teknis, serta kolaborasi dalam proses pengolahan data dan implementasi model **Machine Learning dan Deep Learning**. Penghargaan juga disampaikan kepada **UCI Machine Learning Repository** sebagai penyedia dataset yang digunakan dalam penelitian ini. Akhir kata, penulis berharap hasil penelitian ini dapat memberikan manfaat serta menjadi referensi bagi penelitian selanjutnya, khususnya dalam bidang prediksi dropout mahasiswa dan pengembangan sistem pendukung keputusan berbasis **Machine Learning dan Deep Learning** di lingkungan pendidikan tinggi.

Daftar Pustaka

- [1] J. Han, M. Kamber, and J. Pei, *Data Mining: Concepts and Techniques*, 3rd ed. San Francisco: Morgan Kaufmann, 2012.
- [2] U. Fayyad, G. Piatetsky-Shapiro, and P. Smyth, “From data mining to knowledge discovery in databases,” *AI Magazine*, vol. 17, no. 3, pp. 37–54, 1996.
- [3] C. Romero and S. Ventura, “Educational data mining: A review of the state of the art,” *IEEE Transactions on Systems, Man, and Cybernetics*, vol. 40, no. 6, pp. 601–618, 2010.
- [4] S. Delen, “Predicting student attrition with data mining methods,” *Journal of College Student Retention*, vol. 13, no. 1, pp. 17–35, 2011.
- [5] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning*, 2nd ed. New York: Springer, 2009.
- [6] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [7] T. Chen and C. Guestrin, “XGBoost: A scalable tree boosting system,” in *Proceedings of the 22nd ACM SIGKDD Conference*, 2016, pp. 785–794.
- [8] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. Cambridge: MIT Press, 2016.
- [9] K. P. Murphy, *Machine Learning: A Probabilistic Perspective*. Cambridge: MIT Press, 2012.
- [10] R. B. Santos, M. N. Ribeiro, and J. Bernardino, “A survey on dropout prediction in higher education,” *IEEE Access*, vol. 8, pp. 153215–153230, 2020.